گزارش روند اجرای پروژه

دستیار هوشمند پشتیبانی Streamlit

پروژهٔ نهایی دورهٔ Agentic AI کوئرا

کار را از یک مسئلهٔ مشخص شروع کردیم: در پرسش‌های فنی Streamlit، پاسخ به نسخهٔ کتابخانه، رفتار Widget و وضعیت برنامه وابسته است. اگر اطلاعات کاربر ناقص باشد یا پاسخ از مستندات نسخهٔ دیگری بیاید، یک پیشنهاد ظاهراً درست می‌تواند مسئله را بدتر کند. بنابراین هدف را ساخت دستیار رسیدگی به پرونده گذاشتیم؛ دستیاری که سؤال لازم را بپرسد، شواهد بیاورد و پیشنهادش برای بررسی انسان قابل پیگیری باشد. [1]

اول دامنه و مرز ماژول‌ها را مشخص کردیم

دامنهٔ فنی را بر Widget، Session Stateها، Callback و Rerun متمرکز کردیم. معماری را با یک agent و چهار حوزهٔ مستقل پیش بردیم: هستهٔ تصمیم، داده و بازیابی، Tracker و ابزارها، و رابط و ارزیابی. برای شروع، Python و قراردادهای Pydantic را انتخاب کردیم تا بتوانیم رفتار هسته را با adapterهای آفلاین آزمایش کنیم؛ افزودن framework تازه را به نیاز پیاده‌شده موکول کردیم.

اعضای تیم	حوزهٔ مشارکت در اجرای پروژه
ساسان کلاهی	Core و قراردادها، منطق تصمیم و اصلاح اطلاعات، درگاه مدل و هزینه، اتصال و بازبینی فنی، آماده‌سازی ارائه
سیدحسن سیدمحمدی	جمع‌آوری و آماده‌سازی داده، منابع نسخه‌دار، RAG، ساخت و بازسازی ایندکس
محمد بهنام	Tracker و ابزارهای محلی، SQLite، تأیید انسان و کنترل اجرای تکراری
محمدحسن گل‌محمدیان	رابط Streamlit، اتصال fixture، UIها و زیرساخت ارزیابی و بازبینی خروجی

پیش از مدل واقعی، رفتار هسته را ساختیم

در بنیاد اولیهٔ ۶ اکتبر، مسیرهای پاسخ، سؤال، جست‌وجوی بیشتر و ارجاع را با شواهد و مدل ساختگی اجرا کردیم. برای هر invocation سقف دو تلاش مدل، دو دور بازیابی، دو query در هر دور و هشت گام گذاشتیم. نخستین بنیاد با ۱۴۰ تست بررسی شد؛ در این مرحله هنوز ماندگاری پرونده و کیفیت پاسخ مدل واقعی را اثبات نکرده بودیم. [2]

این گزارش روند تصمیم‌ها، پیاده‌سازی‌ها، مشکلات و آزمون‌های ثبت‌شدهٔ پروژه را تا آماده‌سازی ارائه روایت می‌کند. مبنای نسخهٔ ارائه، commit aa17a4e است. تاریخ تنظیم گزارش ۲۲ اکتبر ۲۰۲۶، برابر با ۳۰ مهر ۱۴۰۵ است.

از اتصال مدل تا تصمیم مستند

تیم دستیار پشتیبانی ۲۲ · Streamlit اکتبر ۲۰۲۶

پس از آماده‌شدن مسیر آفلاین، درگاه Metis را به هسته وصل کردیم. مدل منتخب مسیر نهایی GPT-4o mini بود؛ در پذیرش واقعی، شناسهٔ gpt-4o-mini-2024-07-18 ثبت شد. انتخاب و هزینهٔ هر درخواست را به تنظیم مشخص و receipt همان اجرا پیوند دادیم؛ انتخاب این مدل را نتیجهٔ یک مقایسهٔ جامع یا اثبات برتری عمومی معرفی نکردیم. [3] [10]

اتصال موفق بود، اما خروجی از قواعد عبور نکرد

در نخستین اتصال، provider پاسخ HTTP موفق داد ولی هسته خروجی را نامعتبر شناخت. متن خام آن پاسخ حفظ نشده بود و علت دقیق همان مورد معلوم نماند. در دو بازتولید بعدی، خطای روشن‌تری دیدیم: مدل JSON معتبر می‌داد، اما مسیر ask را بدون next_question انتخاب می‌کرد. پس توضیح schema به‌تنهایی برای رعایت همهٔ قواعد تصمیم کافی نبود.

قواعد وابسته به هر تصمیم را در prompt صریح کردیم، parser سخت‌گیر و کدهای خطای محدود ساختیم و feedback را فقط در تلاش دومِ همان سقف موجود فرستادیم. سپس سؤال معتبر، پاسخ با ارجاع و repair محدود روی ورودی ساختگی بررسی شدند. این مرحله مشکل سازگاری قرارداد را هدف گرفت؛ از آن نرخ دقت عمومی مدل نتیجه نگرفتیم.

اصلاح کاربر باید تصمیم قبلی را هم تغییر می‌داد

در ادامه، مسئله فقط قالب خروجی نبود. اگر کاربر نسخه یا محیط را اصلاح می‌کرد، نگه‌داشتن نتیجهٔ قبلی می‌توانست پاسخ بعدی را منحرف کند. UserTurn و transitionهای وضعیت را ساختیم تا facts فعال، revision و تاریخچهٔ انتساب با هم تغییر کنند. یک نقص مشخص هم پیدا کردیم: گزارش شکست workaround هنوز تشخیص قدیمی را فعال نگه می‌داشت. پس از اصلاح، چهار regression ناموفق و دو کنترل تکرار، هر شش پاس شدند. [2] [4]

از متن فنی آزاد به GroundedPlan رسیدیم

بررسی‌های بعدی نشان دادند ارجاع معتبر الزاماً ادعای درست نمی‌سازد. فیلتر سخت نسخه نیز همهٔ پیشنهادهای ناموجه را نمی‌بست و گاهی مقایسهٔ تاریخی مفید را رد می‌کرد. بنابراین GroundedPlan را اضافه کردیم: مدل مسیر، سؤال یا ارجاع را انتخاب می‌کند و Core متن نقل‌قول و انتساب را می‌سازد. انتخاب به context و شواهد همان درخواست وصل می‌شود؛ شواهد قدیمی یا تغییرکرده نمی‌توانند بی‌صدا جای آن بنشینند. [4]

در بازپخش آفلاین با پیشنهادهای تألیفی ثابت، هر هفت قصد مفید قابل بیان ماند. این نتیجه نشان داد قرارداد محدودتر هنوز بیان تصمیم‌های لازم را ممکن می‌کند؛ مرتبط‌بودن منبع و کفایت معنایی پاسخ همچنان موضوع بررسی جدا بود.

از ماژول‌های جدا تا پروندهٔ ماندگار

تیم دستیار پشتیبانی ۲۲ · Streamlit اکتبر ۲۰۲۶

هم‌زمان با سخت‌سازی تصمیم، ماژول‌های تیم را به یک مسیر استفاده وصل کردیم. در نسخه‌های ابتدایی، ذخیره‌سازی حافظه‌ای برای نمایش رفتار کافی بود؛ اما با restart، پرونده از دست می‌رفت. در گفتگو هم پاسخ کوتاه کاربر، مانند گفتن فقط شمارهٔ نسخه، می‌توانست موضوع اصلی را از context دور کند. این دو مسئله، کار اتصال را از یک فراخوانی سادهٔ مدل فراتر بردند. [2] [5]

سرویس نوبت گفتگو را به Tracker متصل کردیم

CoreTurnService را برای هماهنگ‌کردن ورودی کاربر، وضعیت و اجرای reasoning پیاده کردیم. سپس مسیر HTTP را با Tracker تیم و SQLite یکپارچه کردیم تا رویداد، proposal، revision و outcome در مرزهای مشخص ثبت شوند. اطلاعات لازم گفتگو برای فهم پاسخ کوتاه کاربر حفظ شد؛ facts جاری از سابقهٔ بازنشسته تفکیک شدند.

تأیید انسان را به همان پرونده، revision و محتوای دقیق proposal بستیم. اگر کاربر اطلاعات را اصلاح می‌کرد، approval قدیمی دیگر اعتبار نداشت. شناسهٔ رویداد و عملیات نیز ثابت ماند تا retry نتیجهٔ قبلی را بازگرداند و اجرا یا هزینهٔ تازه نسازد. در پذیرش پایدار، هر ۴۵۷ کنترل پاس شدند و ماندگاری در پنج checkpoint با interpreter تازه بررسی شد؛ مسیر حافظه‌ای به‌عنوان کنترل منفی، شکست ماندگاری را همچنان نشان می‌داد. [2]

از شواهد ساختگی به Chroma واقعی رفتیم

برای اتصال pilot، RAG محلی با ۱۴ منبع و ۳۰ chunk ساختیم. رکوردهای برگشتی همراه با URL، نسخه، شناسه و hash بررسی می‌شدند. نمایش برداری این مسیر Lexical-hash محلی بود؛ یعنی نمایش واژگانی قابل بازتولید برای جست‌وجو، در کنار Chroma. مدل زبانی همان GPT-4o mini بود؛ Lexical-hash نام مدل مولد یا embedding معنایی آموزش‌دیدهٔ پروژه نیست. [2] [6]

آلودگی query به اطلاعات قدیمی را پیدا کردیم

هنگام correction دیدیم query هنوز نسخه‌ها و مقادیر بازنشستهٔ تاریخچه را حمل می‌کند. query بازیابی را از تاریخچهٔ کامل reasoning جدا کردیم و facts فعال و پیام اخیر را مبنا گذاشتیم؛ موضوع اصلی نیز برای جواب کوتاه نسخه حفظ شد. کنترل‌های ده سناریوی تألیفی از ۲ مورد کامل به هر ۱۰ مورد رسیدند. بااین‌حال، در دو درخواست مدل همان سؤال لازم پرسیده شد و منبع نامرتبط هم دیده شد؛ اصلاح query را با بهبود قطعی کیفیت RAG یکی نگرفتیم. [2]

پس از این اتصال، می‌شد یک پرونده را در رابط Streamlit دنبال کرد، اطلاعاتش را تغییر داد و همان وضعیت را از API و storage خواند. تست‌های HTTP، UI و SQLite برای بررسی این رفتار مشترک به کار آمدند؛ موفقیت هر ماژول به‌تنهایی جای پذیرش مسیر کامل را نگرفت.

گسترش منابع و اصلاح مسیر بازیابی

تیم دستیار پشتیبانی ۲۲ · Streamlit اکتبر ۲۰۲۶

با اتصال ایندکس واقعی، دو مسئله را جدا بررسی کردیم: اجرای قابل اعتماد قرارداد خروجی مدل و رساندن شاهد مرتبط به همان درخواست. آزمایش‌های قرارداد و بازیابی در ۱۵ اکتبر انجام شدند؛ build گسترده و پذیرش آن در ۱۷ اکتبر ثبت شد.

وظیفهٔ مدل را در خروجی ساخت‌یافته ساده‌تر کردیم

خطاهای schema، ارجاع ترکیبی و توقف طول، مسئلهٔ دیگری بودند. در آزمایش compact wire، به‌جای کپی شناسه و hash بلند هر منبع، مدل موقعیت صحیح آن را در شواهد همان درخواست انتخاب کرد. gateway این انتخاب را به ارجاع دقیق تبدیل می‌کرد و hash کامل context و validation همچنان برقرار بود؛ همان سقف دو تلاش نیز حفظ شد. [8]

در ۳۲ ارسال ثبت‌شده، schema نامعتبر در بازوی پایه ۳ خروجی از ۱۸ و در compact صفر از ۱۴ بود؛ مسیر کامل نیز از ۴ مورد از ۶ به ۵ مورد رسید. در هیچ بازو، پاسخ فنیِ خواسته‌شده اثبات نشد. این آزمایش دربارهٔ قابلیت اجرای قرارداد خروجی بود و درمان قطعی طول یا بهبود usefulness را ثابت نکرد.

داشتن سند در ایندکس، رسیدن آن به مدل نبود

در بررسی جست‌وجوهای واقعی دیدیم شواهد button در رتبه‌های ۶، ۸ و ۲۰ و شاهد لازم multiselect در رتبهٔ ۲۲ قرار می‌گیرند؛ انتخاب مستقیم پنج نتیجهٔ اول آن‌ها را کنار می‌گذاشت. پنجرهٔ نامزدها را تا ۲۵ باز کردیم، ارتباط query و نسخهٔ فعال کاربر را پیش از انتخاب پنج شاهد نهایی لحاظ کردیم و رکوردهای کامل را با بودجهٔ ۱۲۰۰۰ بایت بسته‌بندی کردیم. [7]

در مقایسهٔ توسعه‌ای ۲۷درخواستی، مسیرهای کامل از ۵ مورد از ۶ به هر ۶ مورد رسیدند؛ راهنمای جزئی icon در هر دو تکرار یک پرونده به خروجی کاربر رسید. اما رسیدن سند multiselect هنوز جواب فنی کامل نساخت و Enum حل نشد. به این ترتیب، بین «سند موجود»، «شاهد انتخاب‌شده» و «پاسخ کافی» فاصلهٔ مشخصی دیدیم.

از pilot به build نهایی و تنظیم نسخه‌دار رسیدیم

پس از pilot، پوشش منابع را گسترش دادیم. مجموعهٔ نهایی v3 به ۱۲۲۸ منبع و ۱۸۲۷ chunk رسید: ۴۷ صفحهٔ مستندات، ۹ release note و ۱۱۷۲ رکورد API از ۴۳ نسخه. منشأ، نسخه و هویت منابع حفظ شد؛ build نیز مستقلاً بازسازی شد و pinهای فیزیکی آن با خروجی تحویل برابر بودند. [6]

برای جدا نگه‌داشتن ارزیابی از retrieval، exclusion فریزشدهٔ ۹۵ Issue و اسناد پاسخ‌محور تعیین‌شده در ساخت منابع اعمال شد. build نهایی هیچ Issue یا comment ایندکس‌شده ندارد. این کار کمک کرد پاسخِ پرونده‌های ارزیابی از مسیر داده به مدل نشت نکند؛ برابری hashها را نیز شاهد بازتولیدپذیری دانستیم، نه اثبات کیفیت معنایی.

برای تحویل، profile صریح grounded_candidate_prefilter_v2 را ثبت کردیم تا پیش‌فیلتر native نسخه نیز پیش از top-k اعمال شود. سازگاری runner، constructor، recipe و metadata بررسی شد. آزمایش‌های مختلف، بدون شاهد و ثبت نسخهٔ مشخص، به‌صورت پنهانی جای تنظیم پذیرفته‌شده ننشستند. [2]

اجرای متصل و آزمون رفتار واقعی

تیم دستیار پشتیبانی ۲۲ · Streamlit اکتبر ۲۰۲۶

پس از اتصال و بازسازی منابع، در پذیرش محدود ۱۷ اکتبر مسیر Streamlit، API، Core، Chroma، درگاه مدل و SQLite را با هم اجرا کردیم. هفت نوبت گفتگو و هشت درخواست واقعی مدل ثبت شد؛ سه نوبت از مرورگر و چهار نوبت از client همان backend بودند. همهٔ درخواست‌های این پذیرش settle شدند و وضعیت نامطمئن تازه‌ای ایجاد نشد. [10]

اصلاح نسخه و تکرار عملیات را در مسیر کامل آزمودیم

در سناریوی correction، نسخهٔ قبلی کنار رفت و نسخهٔ فعال تازه ثبت شد. تأیید مربوط به revision قدیمی با HTTP 409 رد شد و وضعیت را تغییر نداد. backend را واقعاً restart کردیم و هر سه پرونده با همان اطلاعات باز شدند. retry پیام و review نیز Action یا درخواست مدل اضافه نساخت. این‌ها شواهد عملیاتی یک پروندهٔ ماندگار بودند.

آزمون یا شاهد	نتیجهٔ ثبت‌شده	دامنهٔ نتیجه
پذیرش متصل ۱۷ اکتبر	۷ نوبت و ۸ درخواست	اتصال واقعی اجزا و چرخهٔ پرونده؛ ارزیابی نهایی مستقل نیست.
usage همان پذیرش	$0.006429390	برآورد با token و قیمت ثبت‌شده؛ هزینهٔ کل پروژه یا صورتحساب provider نیست.
restart و retry	حفظ ۳ پرونده؛ اجرای اضافه صفر	ماندگاری و بازپخش عملیات در سناریوهای بررسی‌شده.
بررسی توسعهٔ ۱۸ اکتبر	۶۷۳۶ تست موفق	۵ مصرف‌کنندهٔ محافظت‌شده deselect شدند؛ این تست نرم‌افزار است.
طرح ارزیابی	۳۱ پرونده و ۱۴ سناریوی چندنوبتی	۱۶ پروندهٔ توسعه و ۱۵ آزمون؛ موجودی fixtureها، نه ۳۱ مسئلهٔ حل‌شده.

تست‌های توسعه، lint و بررسی قالب کد، در کنار پذیرش‌های هدفمند اجرا شدند. تعداد اجرای تحویل‌های مختلف را با هم جمع نکردیم، چون تست‌های مشترک داشتند. workbench و receiptها نیز برای دیدن شواهد مصرف‌شده و بازبینی پاسخ ساخته شدند؛ شمارش تست نرم‌افزار را به نمرهٔ کیفیت مدل تبدیل نکردیم. [11] [12]

پاسخ واقعی، نقاط قوت و ضعف را هم‌زمان نشان داد

شواهد مرتبط با icon دکمه در نسخهٔ ۱٫۳۹ و type و disabled در نسخهٔ ۱٫۴۹ به پاسخ رسیدند. در مقابل، correction مربوط به multiselect منابع کم‌ربط انتخاب کرد و بعضی متن‌ها بیش از نیاز کاربر طولانی بودند. حل Enum، نمرهٔ نهایی usefulness و کیفیت مستقل held-out تأیید نشده‌اند. اتصال واقعی اجرا شد، اما ارزیابی محتوای پاسخ را از سلامت زیرساخت جدا نگه داشتیم. [10]

بازبینی پاسخ‌ها و حاصل مسیر توسعه

تیم دستیار پشتیبانی Streamlit · ۲۲ اکتبر ۲۰۲۶

طول پاسخ‌ها ما را به خود منبع برگرداند. برای سؤال محدود دربارهٔ یک پارامتر، نقل کل docstring می‌توانست چند هزار کاراکتر بسازد. در یک بررسی آفلاین، تعریف کامل پارامتر را واحد انتخاب قرار دادیم؛ برای نمونه، یکی از متن‌های ۹۵۵۱کاراکتری در candidate تألیفی به ۱۳۵۷ کاراکتر رسید. این بازنویسی کنترل‌شده، انتخاب تازهٔ مدل یا بهبود سنجیده‌شدهٔ تجربهٔ کاربر نبود. [2]

هنگام کوتاه‌سازی، ناسازگاری دادهٔ خام را پیدا کردیم

دیدیم defaultهای type و disabled با signature سازگار نیستند. raw JSON، متن seed و کد رسمی همان نسخه را تطبیق دادیم: metadata برای این دو فیلد null و "is" داشت، ولی signature مقدار "secondary" و False را نشان می‌داد. بازسازی بایت‌به‌بایت مشخص کرد ناسازگاری پیش از retrieval وجود داشته است؛ اختلاف طول excerpt هم با trim مرزی توضیح داده شد. [9]

یک مشتق آفلاین با هویت تازه ساختیم که default صریح را از signature می‌خواند و None، required و مقدار حل‌نشده را جدا نگه می‌داشت. raw JSON و بدنهٔ منبع حفظ شدند. ۸۲۴ تست مرتبط، شامل ۱۲۴ کنترل تازه، این بررسی را پوشش دادند؛ این نتیجه وارد runtime یا build ارائه نشد و رفتار parser تاریخی نیز بازاجرا نشد.

آنچه برای ارائه آماده کردیم

در پایان، جریان متصل محصول را با تصویر واقعی رابط، نمودار معماری و روایت فارسی در ارائهٔ ۱۵اسلایدی جمع کردیم. HTML، PDF و راهنمای گفتاری هم‌نسخه آماده و صفحات و ترکیب RTL و LTR بازبینی شدند. در این مسیر از قرارداد اولیه و adapter آفلاین به منابع نسخه‌دار، پیشنهاد مستند، اصلاح state، بررسی انسان و پروندهٔ ماندگار رسیدیم. تست‌ها و رسیدها، هم موفقیت‌ها و هم محدودیت‌های این مسیر را قابل پیگیری نگه داشتند. [12]

منابع روایت و نتایج

[۱] طراحی معماری و قراردادهای ماژول‌ها

[۲] تاریخچهٔ پیاده‌سازی و تست‌های Core

[۳] اتصال مدل و رفع خطای قواعد تصمیم

[۴] GroundedPlan و اصلاح وضعیت کاربر

[۵] اتصال HTTP و ماندگاری پرونده

[۶] بازسازی مستقل منابع نهایی v3

[۷] مطالعهٔ ارتباط شواهد و بازیابی

[۸] آزمایش قرارداد فشردهٔ خروجی مدل

[۹] بررسی دادهٔ خام و default پارامترها

[۱۰] رسید پذیرش متصل ۱۷ اکتبر

[۱۱] رسید بررسی توسعهٔ ۱۸ اکتبر

[۱۲] منابع ارائه و آمار طراحی ارزیابی